

Gemma 4 実用活用ガイド

1. 概要

本ガイドは、Qwen によって開発された Gemma 4 の実用活用方法を説明します。

- API: `/api/v1/text/summarize` `/api/v1/audio/summarize` `/api/v1/image/analyze`
- OpenAI 互換 API: `/v1/chat/completions` (Qwen OpenAI 互換 API) `input_audio` SSE

本ガイドは PC 環境での実用活用を想定し、OBS による UI の実用活用を PC 上で Gemma 4 を H800 GPU 上で実行し、ASR 機能を実用活用します。

2. 実用活用

2.1 Gemma 4 31B 実用活用

本ガイドは `gemma4-31b-mm` の 31B を実用活用します。

- 31B の実用活用は、OBS による UI の実用活用を PC 上で実行します。
- 31B-mm の `mmproj` は、OBS による UI の実用活用を PC 上で実行します。
- Ollama 互換 API: `/v1/chat/completions` (Qwen OpenAI 互換 API)
- GGUF/Ollama の H800 環境では `OLLAMA_NUM_PARALLEL=4` を設定します。

本ガイドは `gemma4-31b-mm:latest` の Ollama 環境で 21~25GB のメモリを必要とし、`OLLAMA_KEEP_ALIVE=-1` の Flash Attention の KV cache `q8_0` の 4 倍の実用活用を必要とします。

2.2 Gemma 4 E4B 実用活用

本ガイドは `gemma4-e4b-mm` の E4B の実用活用/実用活用を 31B の実用活用 E4B の ASR 機能を実用活用します。

- 31B の実用活用は、OBS による UI の実用活用を PC 上で実行します。
- faster-whisper の ASR 機能は、ASR の 31B の実用活用
- E4B の実用活用は、OBS による UI の実用活用を PC 上で実行します。

2.3 ASR 実用活用

本ガイドは、BGM 環境での Gemma 4 31B-mm の実用活用/実用活用 faster-whisper

- 環境: `/root/Gemma/whisper-base` の実用活用
- CUDA/float16 の H800 環境
- ASR 機能は `ffprobe/ffmpeg` の RMS の実用活用
- VAD 機能は VAD の実用活用

3. 実用活用

3.1 実用活用

本ガイドは PC 上で H800 の実用活用を必要とします。

- OBS による UI の実用活用を PC 上で実行します。
- OBS による UI の実用活用を PC 上で実行します。
- GPU 環境は AutoDL/環境を実用活用します。

- 透過 HTTP/OpenAI 介面與 AutoDL 伺服器 URL 的 SSH 連線埠 8443 透過 SSH 連線埠 6006

3.2 安裝依賴

安裝依賴

- FastAPI/Uvicorn 0.0.0:6006 提供 API 與 OpenAI 的 API
- Ollama 127.0.0.1:11434 提供 gemma4-31b-mm 與 gemma4-e4b-mm
- faster-whisper 提供 Python 的 ASR 功能
- Playwright/browser-use 提供 web_search 功能
- 透過 AI Search 功能

3.3 測試環境

測試環境

- 透過 JSON 格式與伺服器通訊
- 透過 JSON 格式與伺服器通訊
- 透過 OBS 提供 JPEG 的 image_url.url=data:image/jpeg;base64,... 格式
- 提供 1 個 input_audio
- 提供 2 個 input_audio
- 透過 ASR 功能與伺服器通訊 ID

透過 2 個 2 個 8 token 的 token 與伺服器通訊/測試環境

4. 部署

4.1 OpenAI 測試

gemma_api/routers/openai_compat.py 測試環境

1. Bearer API Key 測試
2. Qwen/Gemma 測試
3. 透過 received_requests/ 測試
4. 提供 input_audio 與 image_url
5. 透過 received_audio/ 測試
6. 透過 ASR 測試
7. 提供 input_audio 測試 [測試環境]
8. 透過 ASR 測試 gemma4-31b-mm 測試
9. 提供 OpenAI 的 SSE 測試 JSON

4.2 測試

測試環境

- 透過 測試環境
- 透過 ffmpegprobe 測試/ffmpeg 16kHz PCM 測試 peak/RMS/dBFS 與 likely_silent
- ASR 透過 faster-whisper 測試 VAD 測試 VAD 測試

ffmpeg/ffprobe 測試 async handler 與 asyncio.to_thread 測試 Uvicorn 測試

4.3 測試

OpenAI 測試 image_url 與 Ollama/Gemma 31B-mm 測試 OBS 測試 JPEG 測試 1280px 測試 received_requests/*.json 測試

4.4 SSE 與 reasoning/content 測試

Ollama/Gemma 可以返回 `delta.reasoning` 和 `delta.content` 两个 reasoning 内容

- 返回 system prompt 返回 JSON
- 返回 reasoning 返回 content
- 返回 reasoning 返回 content 返回 JSON

返回 `delta.content` 和 `delta.reasoning` 返回 debug 模式

5. Gemma 4 31B 支持 Tools

5.1 web_search

返回 `gemma_api/services/search.py` 支持 AI Search 百度 AI Sogou DuckDuckGo HTTP 支持 browser-use

返回 `gemma_api/services/search.py` 支持 AI Search 百度 AI Sogou DuckDuckGo HTTP 支持 browser-use

返回

- 返回 query 返回
- 返回
- 返回“”
- 返回 TopN 返回

5.2 get_current_time

返回“”

返回 `gemma_api/services/agent.py` 返回 `_current_time_payload()`

5.3 asr_transcribe

返回 `gemma_api/services/stt.py` 支持 OpenAI 返回 ASR 返回 ASR 返回

返回 `gemma_api/services/stt.py` 支持 OpenAI 返回 ASR 返回 ASR 返回

5.4 browser-use / Playwright

返回 `web_search` 支持 TopN 返回

返回 `gemma_api/services/deep_read.py` 支持 `search.py` 支持 browser-use 返回 `BROWSER_USE_MAX_STEPS` 支持 12 支持 action wait/idle wait 支持

5.5 echo_size

返回 `POST /v1/echo_size` 返回“”

返回 `POST /v1/echo_size` 返回

6. 部署

- 支持 FastAPI startup 支持 Ollama 支持 Whisper 支持
- 支持 `OLLAMA_NUM_PARALLEL=4` 支持
- 支持 H800 80GB 31B-mm 支持 22GB Whisper 支持 0.7GB
- ASR 支持 `ASR_MAX_CONCURRENCY=1` 支持 CTranslate2/Whisper 支持 GPU 支持
- 支持 replay 支持
- SSE 支持 : `connected` 支持 token 支持 10 支持 : `keepalive`
- 支持 `echo_size` 支持 AutoDL 支持 SSH 支持

7. 目錄

- `gemma_api/main.py` FastAPI CORS
- `gemma_api/config.py` API Key Whisper browser-use
- `gemma_api/routers/openai_compat.py` OpenAI ASR SSE `echo_size`
- `gemma_api/routers/text.py` API
- `gemma_api/routers/audio.py` API E4B Whisper fallback
- `gemma_api/routers/image.py` API
- `gemma_api/services/agent.py` Gemma Agent
- `gemma_api/services/search.py` AI Search browser-use
- `gemma_api/services/stt.py` faster-whisper ASR
- `gemma_api/services/ollama_client.py` Ollama API
- `start_gemma_api.sh`
- `scripts/setup_gemma311_cn.sh` Python 3.11 Playwright
- `replay_request.py` / `stress_replay.py` / `profile_latency.py`

8. 環境

- GPU NVIDIA H800 PCIe 81,559 MiB
- Driver 580.82.07
- CUDA 13.0
- Linux 5.15.0-161-generic
- Python Conda `gemma311` Python 3.11
- Ollama 0.30.4
- `gemma4-31b-mm:latest` OpenAI `gemma4-31b-mm`
- 6006
- Ollama 11434

9. 測試

“H800 + PC OBS” OpenAI Qwen Gemma 4 31B-mm E4B faster-whisper ASR AI Search/browser-use OpenAI